Δομές Δεδομένων και Αλγόριθμοι

Ονοματεπώνυμο: Ερμιόνη Φώτη

Α.Μ.: 2020030081

Ημερομηνία : 10/04/2023

Άσκηση 1: Επεξεργασία Αρχείων

Σύντομη Περιγραφή Κώδικα

Κλάσεις και Μέθοδοι

- ***DataClass***
  Η κλάση αυτή περιέχει τα δεδομένα που χρειάζονται. Αποτελείται από έναν ακέραιο αριθμό (int key) και από μία συμβολοσειρά (String data).
- ***DataPage***
  Η κλάση αυτή αντιστοιχεί σε μία σελίδα δίσκου, η οποία έχει μέγεθος 256(int DATA_PAGE_LENGTH=256). Αποτελείται από δύο μεθόδους οι οποίες χρησιμεύουν για το γράψιμο και το διάβασμα της σελίδας στο αρχείο. Συγκεκριμένα, η writeToFile παίρνει τα records της μια σελίδας, τα τοποθετεί σε έναν ByteBuffer (ByteBuffer buf) και όταν εξαντλήσει όλα τα records πηγαίνει και γράφει τον buf στο αρχείο. Από την άλλη μεριά, η ReadFromFile πηγαίνει σε μία σελίδα του αρχείου διαβάζει ένα array από bytes και στην συνέχεια ανακτά τα δεδομένα και τα επιστρέφει σε ένα array από DataClass .
- ***Pair***
  Η κλάση αυτή περιέχει δύο ακέραιους αριθμούς (int key) και (int pageNumber). Ουσιαστικά, αντιστοιχεί το κλειδί με την σελίδα που βρίσκεται στο αρχείο.
- ***IndexPage***
  Η κλάση αυτή αντιστοιχεί σε μία σελίδα δίσκου των αρχείων δεικτοδότησης, τα οποία περιέχουν ζεύγη αριθμών (Pair). Αποτελείται από δύο μεθόδους οι οποίες χρησιμεύουν για το γράψιμο και το διάβασμα της σελίδας στο αρχείο δεικτοδότησης. Συγκεκριμένα, η writeToFile παίρνει τα pairs της μια σελίδας, τα τοποθετεί σε έναν ByteBuffer(ByteBuffer buf) και όταν εξαντλήσει όλα τα pairs της σελίδας πηγαίνει και γράφει τον buf στο αρχείο. Από την άλλη μεριά, η ReadFromFile πηγαίνει σε μία σελίδα του αρχείου δεικτοδότησης διαβάζει έναν array από bytes και στην συνέχεια ανακτά τα δεδομένα και τα επιστρέφει σε ένα array από Pair.
- ***SearchStats***
  Η κλάση αυτή περιέχει δύο long μεταβλητές(t0,t1) , οι οποίες αντιστοιχούν στην στιγμή έναρξη της αναζήτησης (t0) και στην λήξη της αναζήτησης(t1) . Επιπλέον, περιέχει έναν ακέραιο αριθμό (pageReadCount) , που αντιστοιχεί στον αριθμό προσβάσεων στο δίσκο που έχουν πραγματοποιηθεί συνολικά για την αναζήτηση.

- ***Main***
  Η κλάση αυτή εκτελεί τους τρεις τρόπους αναζήτησης. Η μέθοδος για τον τρόπο αναζήτησης Α(SearchA) διαβάζει σειριακά το αρχείο ανά σελίδα (DataPage) μέχρι να εξαντλήσει όλα τα records , ή μέχρι να βρει το κλειδί αναζήτησης. Η μέθοδος για τον τρόπο αναζήτησης Β(searchB) διαβάζει σειριακά το αρχείο δεικτοδότησης, αυτήν την φορά, ανά σελίδα(IndexPage) μέχρι να εξαντλήσει όλα τα pairs, ή μέχρι να βρει το κλειδί αναζήτησης. Όταν το βρει, παίρνει τον αριθμό σελίδας που βρίσκεται το κλειδί στο πρωτεύον αρχείο και ψάχνει μόνο στη συγκεκριμένη σελίδα. Για τον τρόπο αναζήτησης Γ χρησιμοποιούνται δύο μέθοδοι. Η πρώτη μέθοδος(binarySearch) εφαρμόζει δυαδική αναζήτηση στο αρχείο δεικτοδότησης, το οποίο είναι ταξινομημένο αυτή την φορά, μέχρι να βρει το κλειδί αναζήτησης και στην συνέχεια επιστρέφει ένα Pair, δηλαδή το κλειδί αναζήτησης μαζί με τον αριθμό της σελίδας που βρίσκεται στο πρωτεύον αρχείο. Η δεύτερη μέθοδος(search C) καλεί την παραπάνω και εφόσον βρεθεί το κλειδί αναζήτησης πηγαίνει και ψάχνει στη συγκεκριμένη σελίδα του πρωτεύοντος αρχείου. Επιπλέον, περιέχει μεθόδους για την εγγραφή των records στο πρωτεύον αρχείο (buildFile) και την εγγραφή των pairs στο αρχείο δεικτοδότησης(buildIndexFile) αντίστοιχα. Η buildFile καλεί την writeToFile από την κλάση DataPage και γράφει τα records ανά σελίδα στο πρωτεύον αρχείο μέχρι να εξαντληθούν, ενώ ταυτόχρονα δημιουργεί τα pairs για κάθε record. Η buildIndexFile καλεί την writeToFile από την κλάση IndexPage και γράφει τα pairs ανά σελίδα στα αρχεία δεικτοδότησης.

Καταγραφή Αποτελεσμάτων

Ο πρώτος πίνακας αφορά το μέσο αριθμό προσβάσεων στο δίσκο ανά αναζήτηση (πόσες φορές δηλαδή χρειάστηκε να κάνουμε ανάγνωση σελίδας δίσκου για να αποκτήσουμε τα δεδομένα που αντιστοιχούν στο κλειδί που αναζητήσαμε, ή να διαπιστώσουμε ότι δεν υπάρχει το κλειδί που αναζητήσαμε). Για τις μετρήσεις χρησιμοποιήθηκε ακρίβεια 1 δεκαδικού ψηφίου.

	Τρόπος Α		Τρόπος Β		Τρόπος Γ	
N	Αριθμός Προσβάσεων Ανά αναζήτηση. Μέγεθος δεδομένων 55 bytes	Αριθμός Προσβάσεων Ανά αναζήτηση. Μέγεθος δεδομένων 27 bytes	Αριθμός Προσβάσεων Ανά αναζήτηση. Μέγεθος δεδομένων 55 bytes	Αριθμός Προσβάσεων Ανά αναζήτηση. Μέγεθος δεδομένων 27 bytes	Αριθμός Προσβάσεων Ανά αναζήτηση. Μέγεθος δεδομένων 55 bytes	Αριθμός Προσβάσεων Ανά αναζήτηση. Μέγεθος δεδομένων 27 bytes
50	10,8	5,8	2,1	2,2	2,1	2,1
100	19,4	10,1	3,6	3,6	2,4	2,4
200	39,9	20,0	6,0	6,0	2,7	2,7
500	100,6	49,4	13,4	13,1	3,8	3,8
800	152,6	78,8	19,7	20,3	4,5	4,4
1000	196,9	97,2	25,6	25,3	4,6	4,6
2000	397,4	195,7	50,6	49,8	5,5	5,5
5000	973,9	493,2	122,8	124,2	6,8	6,7
10000	1918,3	982,6	240,7	246,5	7,9	7,7
50000	9878,9	5026,2	1235,7	1257,4	10,2	10,1
100000	19672,4	9930,9	2459,6	2483,2	11,1	11,1
200000	38617,9	19724,4	4827,8	4931,6	12,0	12,2

Ο δεύτερος πίνακας αφορά το μέσο χρόνο αναζήτησης ανά αναζήτηση (πόσος χρόνος περνάει για να αποκτήσουμε τα δεδομένα που αντιστοιχούν στο κλειδί που αναζητήσαμε, ή να διαπιστώσουμε ότι δεν υπάρχει το κλειδί που αναζητήσαμε). Ο χρόνος μετρήθηκε σε nanosecond.

	Τρόπος Α		Τρόπος Β		Τρόπος Γ	
Ν	Χρόνος Ανά αναζήτηση. Μέγεθος δεδομένων 55 bytes	Χρόνος Ανά αναζήτηση. Μέγεθος δεδομένων 27 bytes	Χρόνος Ανά αναζήτηση. Μέγεθος δεδομένων 55 bytes	Χρόνος Ανά αναζήτηση. Μέγεθος δεδομένων 27 bytes	Χρόνος Ανά αναζήτηση. Μέγεθος δεδομένων 55 bytes	Χρόνος Ανά αναζήτηση. Μέγεθος δεδομένων 27 bytes
50	43298	40665	10410	19464	8082	8262
100	81343	45929	12714	17668	9537	13324
200	151558	79629	20598	24158	10675	12191
500	352466	186167	41496	46277	12158	13566
800	492384	263950	61563	62742	14424	15021
1000	615941	323358	80509	77205	14867	15788
2000	1258205	657272	158508	156178	17343	17462
5000	3058287	1640150	382432	393145	24242	21731
10000	5964012	3250179	737199	765158	25116	25041
50000	31385106	16741069	3843062	3942932	34704	32806
100000	62501594	33431575	7622446	7657553	40055	36355
200000	122542137	66424930	14992759	15409037	41905	42342

Γραφικές Παραστάσεις

- *Μέσος Αριθμός Προσβάσεων στο Δίσκο/Πλήθος Εγγραφών*

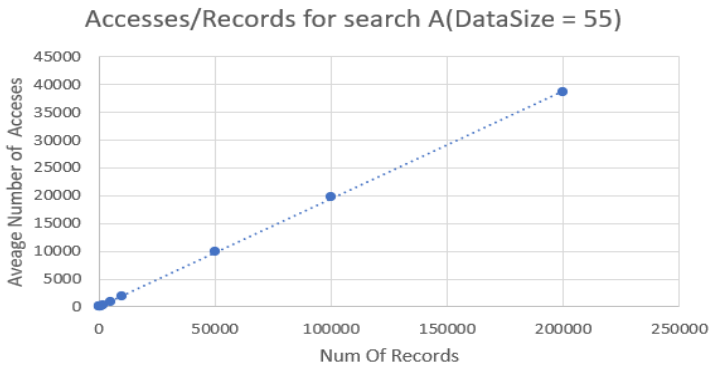

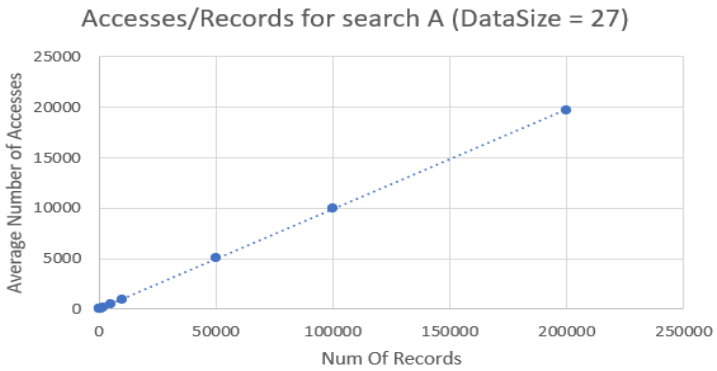

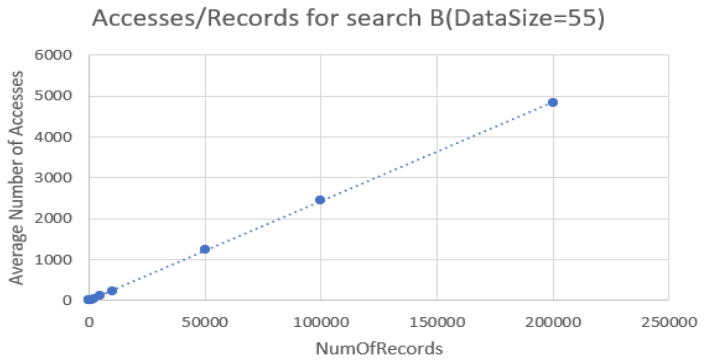

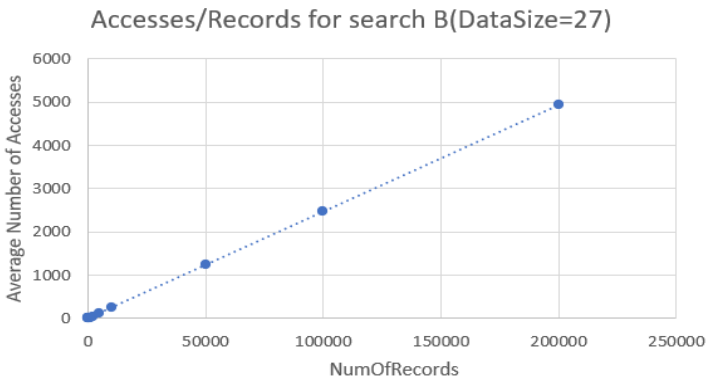

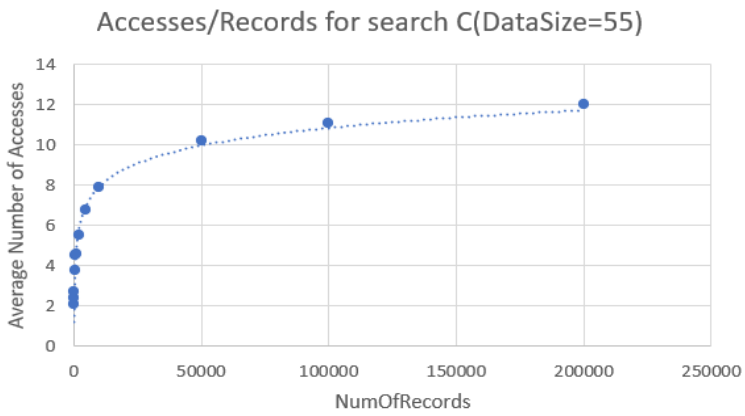

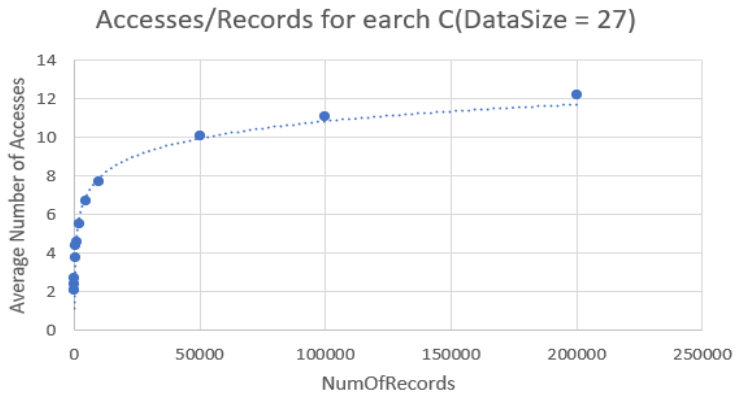

- *Μέσος Χρόνος Αναζήτησης /Πλήθος Εγγραφών*

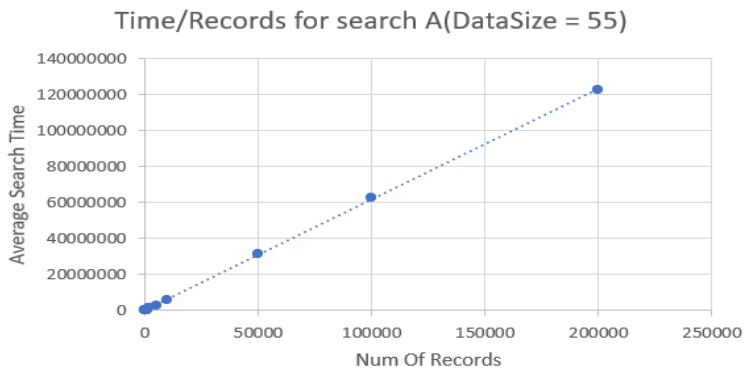

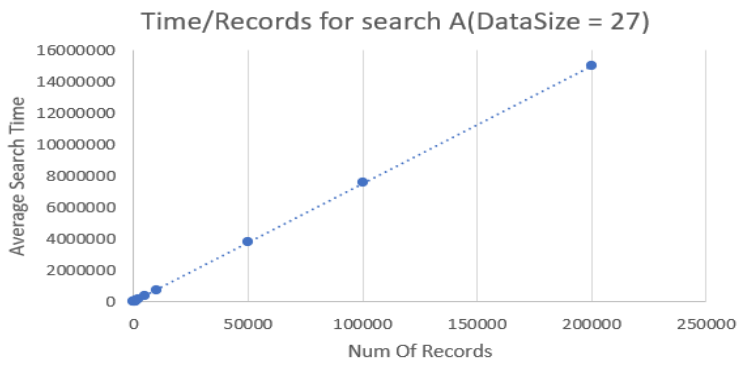

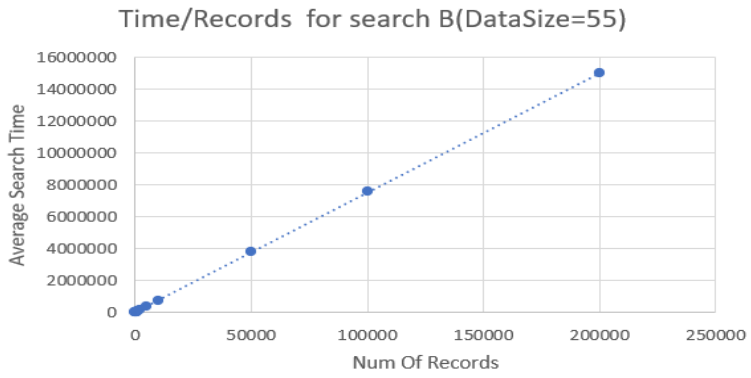
Time/Records for search B(DataSize=55)
Average Search Time
16000000
14000000
12000000
10000000
8000000
6000000
4000000
2000000
0
0
50000
100000
150000
200000
250000
Num Of Records

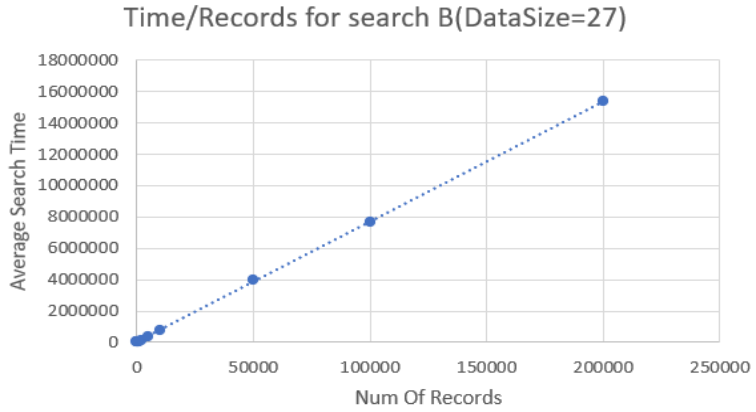
Time/Records for search B(DataSize=27)
Average Search Time
18000000
16000000
14000000
12000000
10000000
8000000
6000000
4000000
2000000
0
0
50000
100000
150000
200000
250000
Num Of Records

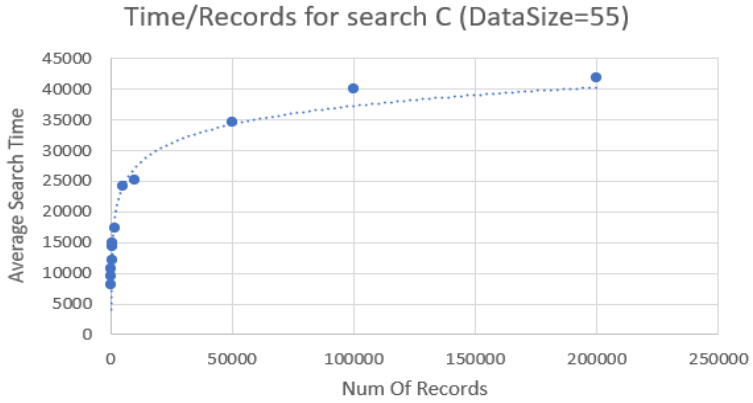
Time/Records for search C (DataSize=55)
Average Search Time
45000
40000
35000
30000
25000
20000
15000
10000
5000
0
0
50000
100000
150000
200000
250000
Num Of Records

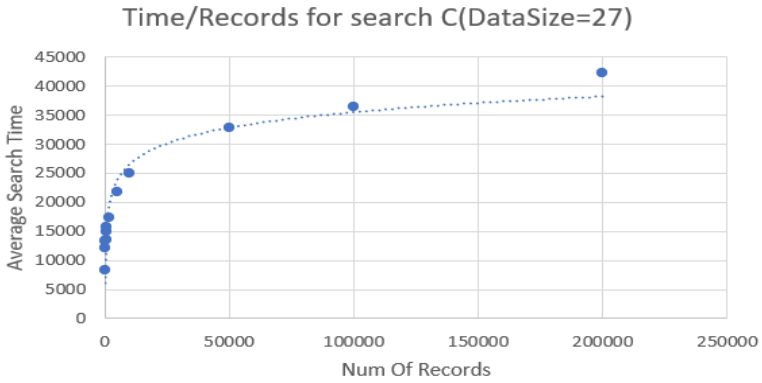
Time/Records for search C(DataSize=27)
Average Search Time
45000
40000
35000
30000
25000
20000
15000
10000
5000
0
0
50000
100000
150000
200000
250000
Num Of Records

Σχολιασμός

Παρατηρώντας τις παραπάνω γραφικές παραστάσεις , μπορεί να δει κανείς ότι για τους τρόπους αναζήτησης Α και Β , οι καμπύλες που προκύπτουν και για τον μέσο χρόνο αναζήτησης, αλλά και για τον μέσο αριθμό προσβάσεων στο δίσκο έχουν γραμμική μορφή , ενώ για τον τρόπο αναζήτησης C έχουν λογαριθμική. Η μορφή που έχουν οι γραφικές παραστάσεις επιβεβαιώνεται και από την θεωρία καθώς οι σειριακές αναζητήσεις, όπως είναι η Α και Β ,εμφανίζουν πολυπλοκότητα O(n) , ενώ από την άλλη μεριά η δυαδική αναζήτηση που εφαρμόζεται στον C τρόπο εμφανίζει πολυπλοκότητα O(logn).

Στους δύο πρώτους τρόπους αναζήτησης, λόγω της γραμμικότητας προκύπτει ότι όσο αυξάνεται το μέγεθος των δεδομένων τόσο αυξάνεται ο μέσος αριθμός προσβάσεων στο δίσκο και ο μέσος χρόνος αναζήτησης αντίστοιχα. Εξετάζοντας , βέβαια, τους πίνακες αποτελεσμάτων βλέπουμε ότι αυτό δεν ισχύει σε όλες τις περιπτώσεις και πολλές φορές για ίδιο αριθμό στιγμιοτύπων εμφανίζεται μικρότερος μέσος αριθμός προσβάσεων και μικρότερος μέσος χρόνος αναζήτησης για DataSize = 55 από ότι για DataSize = 27. Αυτό πιθανότατα οφείλεται στο δίσκο που διαθέτει ο υπολογιστής. Όσον αφορά τον τρίτο τρόπο αναζήτησης οι γραφικές παραστάσεις και του μέσου χρόνου αναζήτησης, αλλά και του μέσου αριθμού προσβάσεων δεν διαφοροποιούνται σημαντικά με την αλλαγή του μεγέθους δεδομένων(DataSize).

Επιπλέον, συγκρίνοντας τις γραφικές παραστάσεις του Α και Β τρόπου αναζήτησης παρατηρεί κανείς ότι η κλίση είναι μεγαλύτερη στον τρόπο αναζήτησης Α για μέγεθος δεδομένων 55. Αυτό σημαίνει ότι ο τρόπος αναζήτησης Α απαιτεί μεγαλύτερο αριθμό προσβάσεων αλλά και περισσότερο χρόνο αναζήτησης για να αποκτηθούν τα δεδομένα που αντιστοιχούν στο κλειδί που αναζητήθηκε ή να διαπιστωθεί ότι δεν υπάρχει το κλειδί αναζήτησης.

Συνοψίζοντας, παρατηρούμε ότι ο τρόπος αναζήτησης C είναι ο πιο αποτελεσματικός καθώς απαιτεί τον μικρότερο αριθμό προσβάσεων στο δίσκο αλλά και τον μικρότερο χρόνο αναζήτησης. Πρέπει να σημειωθεί όμως ότι ο τρόπος αναζήτησης C μπορεί να εφαρμοστεί μόνο σε ταξινομημένο αρχείο δεικτοδότησης. Από τους δύο άλλους τρόπους, αν και ο Β απαιτεί την δημιουργία ενός επιπλέον αρχείου δεικτοδότησης θεωρείται περισσότερο αποτελεσματικός από τον Α , καθώς περιέχει μόνο τα κλειδιά αναζήτησης μαζί με την σελίδα που βρίσκονται και όχι όλα τα δεδομένα. Συνεπώς , σε σχέση με τον Α απαιτεί μικρότερο αριθμό προσβάσεων στον δίσκο και μικρότερο χρόνο αναζήτησης.